

БДЗ №2: Машинный перевод (DE → EN)

Отчёт об экспериментах

Шайко Александр

17 марта 2026 г.

Содержание

1	Общие компоненты всех моделей	2
2	Эксперимент 1: Базовая модель	3
2.1	Параметры	3
2.2	Результаты	3
3	Эксперимент 2: Углублённая модель	3
3.1	Изменения по сравнению с экспериментом 1	3
3.2	Параметры	4
3.3	Результаты	4
4	Эксперимент 3	5
4.1	Параметры	5
4.2	Результаты	5
5	Эксперимент 4	6
5.1	Параметры	6
5.2	Результаты	6
6	Эксперимент 5	7
6.1	Параметры	7
6.2	Результаты	7

1 Общие компоненты всех моделей

- **Позиционное кодирование:** синусоидальное, как в оригинальной статье (что было описано в лекции):

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right), \quad PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

- **Weight tying:** матрица весов выходного линейного слоя совпадает с матрицей эмбеддингов целевого языка — уменьшает число параметров и улучшает качество, потому что по сути, когда мы получаем вероятности, то мы просто смотрим на коллинеарность полученного вектора с уже существующими для того, чтобы выбрать на какой он наиболее похож и затем перевести обратно в слово.
- **Xavier инициализация:** все матрицы весов инициализировались с использованием специального метода xavier uniform, поскольку благодаря этому модель сразу начинала с хороших значений bleu.
- **Маски:**
 - Padding mask — позиции <pad> не участвуют в attention
 - Causal mask для декодера — верхнетреугольная маска, запрещающая смотреть в будущее, т.е. извлекать информацию об окружении из токенов, которые не были выданы моделью на шаге существования данного токена
- **Label smoothing:** $\alpha = 0.1$
- **Gradient clipping:** clip_grad_norm_(max_norm=1.0) — сохраняет направление градиентов, масштабируя их норму
- **Динамический паддинг:** батчи паддируются до максимальной длины в батче + 5
- **Усреднение весов (SWA):** по завершении обучения усреднялись веса топ-5 чекпоинтов по val bleu, хотя на самом деле самое крутое качество на тесте пробивали просто сохраненные модели с самым большим bleu на валидации.
- **Learning rate schedule:** формула из оригинальной статьи:

$$lr = d_{\text{model}}^{-0.5} \cdot \min(\text{step}^{-0.5}, \text{step} \cdot \text{warmup}^{-1.5})$$

2 Эксперимент 1: Базовая модель

2.1 Параметры

Таблица 1: Гиперпараметры эксперимента 1

Параметр	Значение
Количество слоёв энкодера/декодера	3 + 3
Размерность эмбеддингов d_{model}	512
Количество голов attention	8
Размерность FFN d_{ff}	2048
Dropout	0.1
Оптимизатор	AdamW
Weight decay	0.01
$\beta_1, \beta_2, \varepsilon$	0.9, 0.98, 10^{-9}
Warmup шагов	4000
Размер батча (train)	64
Количество эпох	20
Val bleu считался на	5 примерах
Инференс	Greedy search

2.2 Результаты

Модель обучалась около 3.5 часов и, как итог, усредненная модель, получаемая по топ-5 чекпоинтам с наибольшими val bleu (которые, кстати, только в этой базовой модели я считал на 5 примерах), получила качество на тесте 22.63. И я тогда подумал, что можно попробовать закинуть модель, которая на валидации показала самый большой val bleu. И это сработало! Такая модель показала качество на тесте 29.06.

Наблюдения:

- Лучшее качество достигнуто на эпохе 10: val bleu = 29.36
- Val bleu считался лишь на 5 примерах — высокая дисперсия оценки, поэтому по графикам на wandb можно будет видеть, как скачет качество на валидации
- Усреднённая модель показала val bleu = 24.23, что хуже лучшего чекпоинта — вероятно из-за небольшого числа примеров для оценки
- После эпохи 10 наблюдалось переобучение: val loss начал расти

3 Эксперимент 2: Углублённая модель

3.1 Изменения по сравнению с экспериментом 1

- Увеличено количество слоёв: 3 → 6 (как в оригинальном Transformer)
- Увеличен warmup: 4000 → 8000 шагов (более сложная модель требует дольше разгоняться и плюс мне показалось, что для предыдущей модели нехватило шагов для разгона)

- Val bleu считается на 300 примерах вместо 5 — более стабильная оценка
- Добавлен early stopping по val bleu (patience = 5)

3.2 Параметры

Таблица 2: Гиперпараметры эксперимента 2

Параметр	Значение
Количество слоёв энкодера/декодера	6 + 6
Размерность эмбеддингов d_{model}	512
Количество голов attention	8
Размерность FFN	2048
Dropout	0.1
Оптимизатор	AdamW
Weight decay	0.01
$\beta_1, \beta_2, \varepsilon$	0.9, 0.98, 10^{-9}
Warmup шагов	8000
Размер батча (train / val)	128 / 64
Максимум эпох	20
Early stopping (patience)	5 эпох без улучшения bleu
Val bleu считался на	300 примерах

3.3 Результаты

Эта модель уже обучалась 5.5 часов, но и результаты у нее оказались сильно мощнее. На валидации выбивалось качество даже больше 38 по bleu. Тем не менее, усредненная модель снова не показала себя с сильной стороны и получила качество на тесте 26.61. При этом, когда я взял модель уже с лучшим val bleu на валидации, то она показала лучшее качество на тесте среди всех: 30.48

4 Эксперимент 3

4.1 Параметры

Таблица 3: Гиперпараметры эксперимента 3 (vital-sun-4)

Параметр	Значение
Количество слоёв энкодера/декодера	$4 + 4$
Размерность эмбедингов d_{model}	512
Количество голов attention	8
Размерность FFN d_{ff}	2048
Dropout	0.1
Оптимизатор	AdamW
Weight decay	0.01
$\beta_1, \beta_2, \varepsilon$	0.9, 0.98, 10^{-9}
Warmup шагов	8000
Размер батча (train)	128
Количество эпох	11
Валидация	на 300 примерах считаем метрику bleu
Инференс	Greedy search

4.2 Результаты

Тут я решил облегчить модель в результате чего она обучалась всего лишь 2.5 часа (мало слоев), но при этом увеличил количество примеров в батче. Однако из-за траблов с интернетом так и не получилось ее протестировать, потому что сломался кеггл и я не смог выгрузить веса.

5 Эксперимент 4

5.1 Параметры

Таблица 4: Гиперпараметры эксперимента 4 (hopeful-smoke)

Параметр	Значение
Количество слоёв энкодера/декодера	1 + 1
Размерность эмбедингов d_{model}	512
Количество голов attention	8
Размерность FFN d_{ff}	2048
Dropout	0.1
Оптимизатор	AdamW
Weight decay	0.01
$\beta_1, \beta_2, \varepsilon$	0.9, 0.98, 10^{-9}
Warmup шагов	8000
Размер батча (train / val)	128 / 64
Количество эпох	15
Val BLEU считался на	300 примерах
Early stopping (patience)	5 эпох
Инференс	Greedy search

5.2 Результаты

Очень легковесная модель с всего лишь 1 слоем у энкодера и декодера в результате чего она обучилась очень быстро. Из нее я решил загрузить ту, которая дала наибольшее качество на валидации и на тесте получил 26.6 - в целом неплохое качество

6 Эксперимент 5

6.1 Параметры

Таблица 5: Гиперпараметры эксперимента 5 (playful-wind-5)

Параметр	Значение
Количество слоёв энкодера/декодера	1 + 1
Размерность эмбедингов d_{model}	512
Количество голов attention	8
Размерность FFN d_{ff}	2048
Dropout	0.1
Оптимизатор	AdamW
Weight decay	0.01
$\beta_1, \beta_2, \varepsilon$	0.9, 0.98, 10^{-9}
Warmup шагов	8000
Размер батча (train)	128
Количество эпох	15
Валидация	Нет (train + val объединены)

6.2 Результаты

Хотя на валидации всего 900+ примеров, я все же решил объединить трейн и валидацию, что в целом дало неплохие результаты. Усредненная модель на валидации дала качество 28 с лишним. На тесте снова не смог проверить из-за траблов с интернетом.